Aplicación de regresión logística

En esta clase vamos a complementar la lección anterior.

Vamos a ver como los datos del modelo se ajustan para parecerse a las etiquetas o categorías del dataset. Haciendo que sea la función ideal para el problema de clasificación y de aquí sale la función de Cross - Entropy.

In [ ]:
```
from mpl_toolkits.mplot3d import Axes3D
import matplotlib.pyplot as plt
from matplotlib import cm   #Acceder a paletas de colores
import numpy as np
import pandas as pd
import seaborn as sns
```

MLE como base para la regresión logística

Consideramos el problema de MLE:

$$\max \sum_i \log P(y_i|x_i;h)$$

donde:

y_i: clase o categoría de cada elemento y x_i: son los atributos de cada elemento, donde además cada elemento del dataset satisface una distribución de Bernoulli:

$$P \begin{cases} P & y=1 \quad \text{cuando el resultado es exitoso.} \\ 1-P & y=0 \quad \text{cuando el resultado no es exitoso.} \end{cases}$$

En este caso la verosimilitud está dada por:

$$L = \hat{y}y + (1-\hat{y})(1-y)$$

Esta función da como resultado probabilidades altas cuando $\hat{y} \sim y$.

Vamos a construir una gráfica tridimensional de 2 variables de verosimilitud. Recordemos que:

- y_i : Categoría o atributo del dataset
- x_i : Dato de la categoría.
- h : Hipótesis de modelamiento (atributos) - Sigmoide

Vamos a realizar una función en Python donde $\hat{y} = yp$ y es correspondiente a la **función sigmoidal**

In [ ]:
```
#Definiendo función L
def likelihood(y,yp):
    return yp*y + ((1-yp)*(1-y))
```

Lo que queremos es visualizar la función para tener una claridad de lo que esta función representa.

Explicación

Vamos a realizar una gráfica de la función `likelihood(y,yp)`, como se puede observar es una función de 2 variables y como es usual en el cálculo de funciones de 2 variables, tenemos que hacer una gráfica de 3 dimensiones:

> donde los ejes (x, y) son el plano horizontal y el eje vertical es z así $z =$ valores de la verosimilitud.

In [ ]:
```
#creando un objeto figura
fig = plt.figure()
#creando ejes
axes= plt.axes(projection='3d')
```

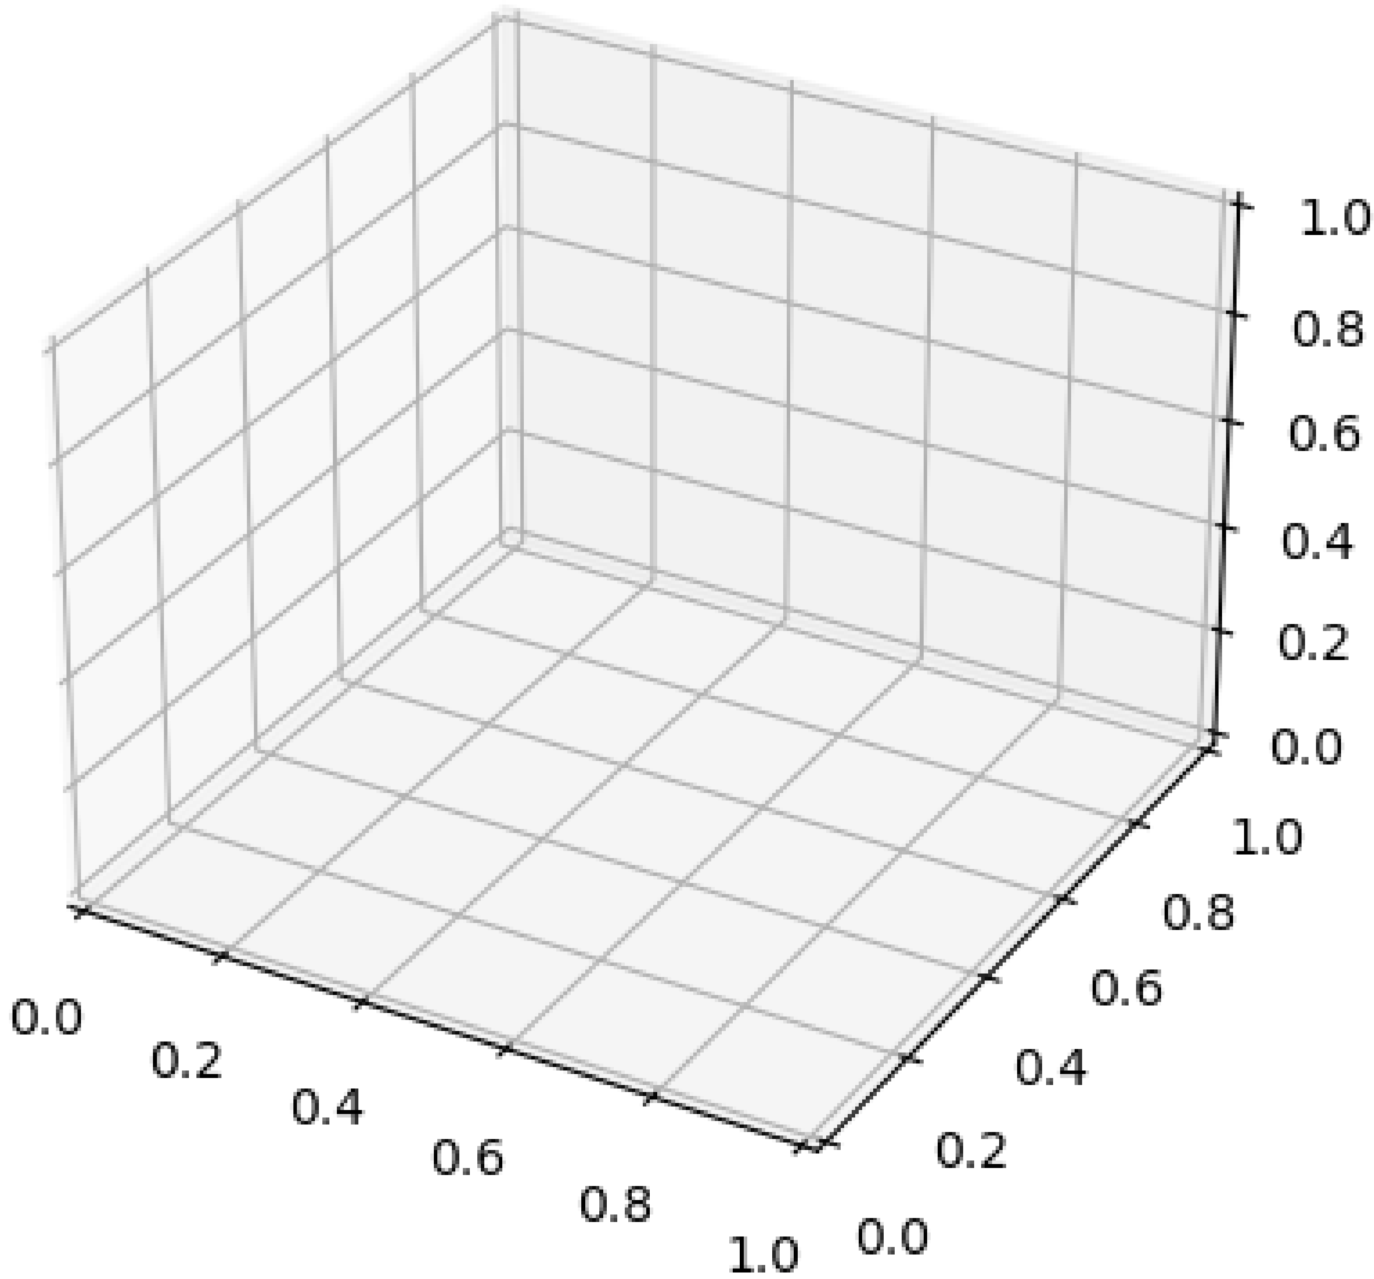


```
In [ ]: #definiendo valores para graficar función
        y=np.arange(0,1,0.1)    #Valores entre 0 y 1 porque son probabil
        yp=np.arange(0,1,0.1)   #Exactamente igual

        #Creando malla para trabajar con el plano (cuadricula)
        y,yp = np.meshgrid(y,yp)
        #con la linea anterior convierto a una malla los valores y,yp

        #calculo la función "z" sobre cada elemento de la malla
        z=likelihood(y,yp)
```

```
In [ ]: #creando un objeto figura
        fig = plt.figure()
        #creando ejes
        axes= plt.axes(projection='3d')
        #Creando la superficie en el espacio de tridimensional
        #Gráfica de 2 variables
        surf = axes.plot_surface(y, yp, z, cmap=cm.coolwarm,
                               linewidth=0, antialiased=False)
        fig.colorbar(surf, shrink=0.5, aspect=5)
        axes.set_xlabel('Data set y')
        axes.set_ylabel('Data modelo yp')
        axes.set_zlabel('Verosimilitud z')

        plt.show()
```

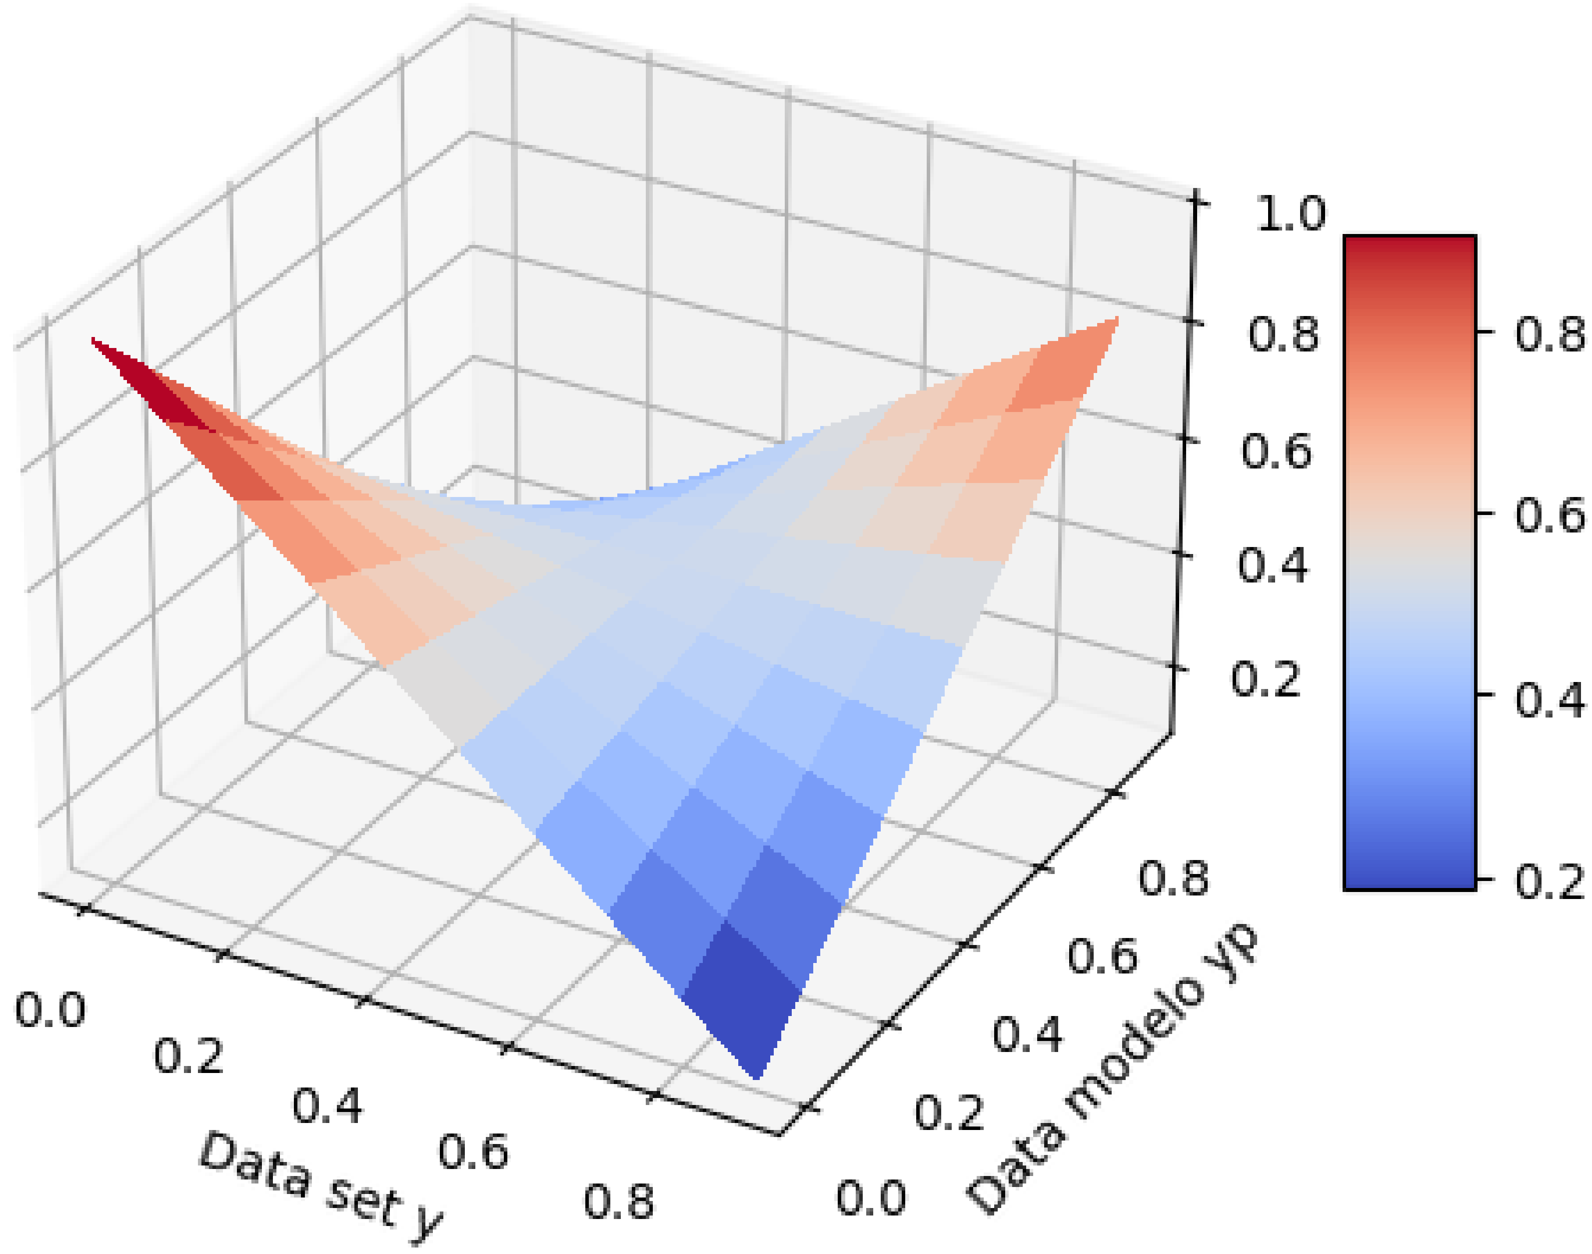

Lo que representa la gráfica es que nuestra función de verosimilitud tiene máximos justo donde los necesitamos. Es decir cuando data set y y data del modelo $\hat{y}$ (0,0) y (1,1). Dando las probabilidades altas o las mas altas, justo cuando ambas $(y - \hat{y})$ coinciden. La visualización justifica este análisis

Considerando $p \to \log(p)$ y sumando la verosimilitud para todos los puntos del dataset obtenemos:

$$\max L = \min(-L)$$

En otras palabras; maximizar quiere decir minimizar **el negativo de Verosimilitud**. De manera al proceso de minimizar $-L$ es optimizar esa función en un problema de clasificación y se conoce como **Cross Entropy - Entropía Cruzada**. Y se define como:

$$CE = \underbrace{-\sum_i \left[\, y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \,\right]}_{\text{Costo} \ \to \ \text{Clasificación}}$$

Regresión Logística con Scikit Learn

Recordemos que:

$$\hat{y} = \frac{1}{1 - \exp\left(-\text{log-odds}\right)}$$

donde:
$\text{log-odds} = \beta_0 x_0 + \beta_1 x_1 + \ldots \beta_n x_n$ y los betas son los parámetros del modelo.

Aplicaremos un ejercicio de clasificación simple con el dataset Iris:

- https://en.wikipedia.org/wiki/Iris_flower_data_set
- https://scikit-learn.org/stable/auto_examples/datasets/plot_iris_dataset.html

In [ ]:
```
from sklearn.datasets import load_iris
from sklearn.linear_model import LogisticRegression

atrib_names = ['sepal length', 'sepal width', 'petal length', 'pe
X, y = load_iris(return_X_y=True)
```

La variable X contiene los datos de los parámetros. Es decir las filas o el numero de flores con sus atributos.

In [ ]:
```
X[0]
```

Out[ ]:
```
array([5.1, 3.5, 1.4, 0.2])
```

In [ ]:
```
len(X)
```

Out[ ]:
```
150
```

La variable `X` contiene 150 elementos, es decir 150 flores. Dentro de ellas en la variable `y` contiene un numero que esta referido a una categoría de flor. Eso quiere decir que hay 3 categorías o tipos de flor. Veamos:

In [ ]:
```
y
```

```
Out[ ]: array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0,
       0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2,
2, 2, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,
2, 2, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2])
```

```
In [ ]: len(y)
```

```
Out[ ]: 150
```

Entonces si queremos tomar las 2 primeras categorías tenemos que tomar, los 100 primeros elementos

```
In [ ]: y[:100]
```

```
Out[ ]: array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0,
       0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1])
```

Comprobemos que si colocamos `101` nos dará el primer elemento de la tercera categoría.

```
In [ ]: y[:101]
```

```
Out[ ]: array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0,
       0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2])
```

Comprobado, el siguiente paso es construir el modelo.

La idea es que la función que llamamos `Logistic Regression` la declaremos para hacer un modelo de clasificación, donde el `random_state` es un generador aleatorio que inicializa a las variables del modelo y `solver=liblinear` es el método de optimización del modelo.

Todo esto es para encontrar la mejor combinación de parámetros, y después le decimos al modelo que se ajuste a los datos. **¿cuales datos?** los de las 2 primeras clases `x[:100],y[:100]`. Con esto el modelo quedaría listo, porque fue ajustado con el fit()

In [ ]:
```
#Ajustando y creando modelo de clasificación
clf = LogisticRegression(random_state=10,
    solver='liblinear').fit(X[:100], y[:100])
```

Ahora le dire que me muestre los **coeficientes** del modelo.

In [ ]:
```
clf.coef_
```

Out[ ]:
```
array([[-0.40247392, -1.46382925,  2.23785648,  1.00009294]])
```

Lo interesante aquí es darnos cuenta de que los 4 números anteriores:

```
array([[-0.40247392, -1.46382925,  2.23785648,
1.00009294]])
```
son los $\beta's$ asociados precisamente a las 4 variables.

Entonces lo que me dice el modelo es que, las anteriores 4 betas son los parámetros que mejor ajustan en el modelo de clasificación, a las categorías dadas por `y[:100]` (las categorías).

In [ ]:
```
model_coefs = pd.DataFrame(clf.coef_, columns=atrib_names)
model_coefs
```

Out[ ]:

	sepal length	sepal width	petal length	petal width
0	-0.402474	-1.463829	2.237856	1.000093

Extras:

Hola 👏 acá les dejo 3 videos adicionales para complementar esta clase y entender mejor la regresión logística. .

Explicación teórica:

- https://www.youtube.com/watch?v=hJbOaMpjnsA
- https://www.youtube.com/watch?v=yIYKR4sgzI8

Explicación y aplicación con python:

- https://www.youtube.com/watch?v=BHok3wJpmf0 .

Espero que este aporte les sea de utilidad. #NuncaParenDeAprender

---

Recursos

- The iris dataset
- The iris dataset - Wikipedia
- Logistic Regression
- Colab código